Mini Proposal

A. Information

- **Project / Mã và Tên đề tài:** A.22. Building a Simple Graph-Based Question Answering Tool
- **Course / Môn học:** IS353.R11
- **Duration / Thời gian thực hiện:** 9/2026 – 12/2026
- **Group / Nhóm**: 13
- **Members / Thành viên:**

1. Nguyễn Gia Bảo, 23520121, 23520121@gm.uit.edu.vn
2. Nguyễn Lan Hương, 23520588, 23520588@gm.uit.edu.vn
3. Phạm Bá Bằng, 23520090, 23520090@gm.uit.edu.vn
4. Thái Văn Vũ, 23521816, 23521816@gm.uit.edu.vn
5. Đặng Thiên Ân, 23520003, 23520003@gm.uit.edu.vn
6. Nguyễn Hữu Minh Khôi, 23520775, 23520775@gm.uit.edu.vn

- **Supervisor / Giảng viên hướng dẫn**: Trần Hưng Nghiệp, nghiepth@uit.edu.vn

B. Content (~2 pages)

1. Mini Problem Formulation

- Project description: Người dùng mạng xã hội thường muốn hỏi những câu về quan hệ như "bạn của bạn tôi làm ở công ty nào?" nhưng không biết ngôn ngữ truy vấn đồ thị. Đồ án xây dựng một công cụ hỏi đáp (QA) trên đồ thị mạng xã hội LDBC SNB lưu trong Neo4j: câu hỏi tiếng Anh được một LLM mã nguồn mở cỡ nhỏ (gpt-oss-20b, gọi qua Groq API) chuyển thành truy vấn Cypher, thực thi trên đồ thị và trả lời bằng văn bản. Bài toán được hình thức hóa thành Text-to-Cypher (semantic parsing). Nhóm so sánh pipeline đề xuất (bổ sung schema, liên kết thực thể, ví dụ few-shot, tự sửa lỗi) với các baseline từ đơn giản đến mạnh — rule-based, LLM nhỏ zero-shot và LLM mạnh zero-shot — bằng execution accuracy trên bộ câu hỏi tự xây dựng theo guideline có kiểm tra chéo, với quy trình chống rò rỉ dữ liệu giữa dev và test.
- Assumptions, constraints, scope:
  - Giả định: đồ thị là một snapshot tĩnh; schema đã biết; mỗi câu hỏi trong bộ test có đáp án xác định (không mơ hồ, không có đồng hạng).
  - Ràng buộc: phần lớn máy thành viên không có GPU nên LLM mã nguồn mở được gọi qua Groq API (miễn phí, nhanh, cả nhóm dùng chung một model); Neo4j Community chạy trong Docker, dự kiến một máy làm server chung truy cập qua mạng riêng (Neo4j Aura Free không đủ dung lượng: giới hạn ~200K node/400K quan hệ). Groq giới hạn request và token theo phút/ngày: đo thực tế mỗi model khoảng 200K token/ngày (8K token/phút, hồi dần theo giờ; token prompt được cache không bị tính), mỗi câu tốn khoảng 1.000–1.300 token kể cả phần suy luận, nên mỗi model chỉ chạy được khoảng 150–200 câu/ngày → cache toàn bộ output, chạy theo lô; Groq có thể đổi hoặc gỡ model (Llama-3.1-8B và Llama-3.3-70B đã bị gỡ ngày 16/08/2026, nhóm chuyển sang gpt-oss-20b/120b) → chỉ dùng model production, ghi rõ ID model và ngày chạy. Thời gian 1 học kỳ.
  - Phạm vi: 5 loại câu hỏi — tra cứu 1-hop, tổng hợp/đếm, multi-hop, đường đi ngắn nhất, lọc theo thời gian.
  - Ngoài phạm vi: hội thoại nhiều lượt, câu hỏi ý kiến/mở, cập nhật dữ liệu đồ thị, dữ liệu người dùng thật, giao diện phức tạp (đăng nhập, nhiều người dùng, triển khai lên server).
- Existing approaches & research gap: Text-to-SQL (Spider, DIN-SQL, DAIL-SQL); Text-to-Cypher mới có bộ dữ liệu tổng hợp đa miền (Neo4j Text2Cypher 2024) và công cụ zero-shot (LangChain GraphCypherQAChain), phần lớn đánh giá với LLM thương mại cỡ lớn. Chưa có bộ câu hỏi ngôn ngữ tự nhiên cho LDBC SNB (benchmark này chỉ có truy vấn viết tay), ít đánh giá với LLM mã nguồn mở cỡ nhỏ, và các "bẫy" đặc thù của đồ thị mạng xã hội chưa được phân tích: trong dữ liệu có 166 họ tên bị trùng giữa các người khác nhau, tên thực thể dùng dấu gạch dưới (United_States), vị trí phân cấp Person→City→Country.
- Research questions & hypotheses:
  - RQ1: LLM zero-shot tốt hơn rule-based ở loại câu hỏi nào? — H1: vượt trội ở multi-hop và câu diễn đạt tự do; tương đương ở tra cứu 1-hop.
  - RQ2: Thành phần nào của pipeline đề xuất đóng góp nhiều nhất? — H2: liên kết thực thể và tự sửa lỗi giảm mạnh nhất tỉ lệ truy vấn lỗi/rỗng.

    - RQ3: Model nhỏ (gpt-oss-20b) + pipeline đề xuất tiến gần model mạnh zero-shot (B3, gpt-oss-120b) đến đâu, và pipeline còn giúp được model mạnh không? — H3: pipeline thu hẹp phần lớn khoảng cách ở multi-hop/temporal; lợi ích trên model mạnh nhỏ hơn nhưng vẫn dương nhờ liên kết thực thể.
- Objectives & contributions: (1) đồ thị LDBC SNB SF0.1 trong Neo4j (đã hoàn thành); (2) bộ 242 câu hỏi tiếng Anh có Cypher và đáp án đúng, xây theo guideline có kiểm tra chéo (đã hoàn thành: dev 92, test 150); (3) công cụ QA end-to-end (Neo4j trên máy nhóm, LLM gọi qua Groq API), có giao diện chat web đơn giản (Streamlit) hiển thị câu trả lời, câu Cypher sinh ra và kết quả truy vấn; (4) so sánh proposed với baseline yếu lẫn mạnh, ablation và phân tích lỗi. Đóng góp: bộ benchmark QA cho LDBC SNB kèm guideline, mã nguồn tái lập được, phân tích lỗi Text-to-Cypher của LLM nhỏ so với LLM mạnh.

2. Related Work

- **Text-to-SQL** (Spider [4]; DIN-SQL [6], DAIL-SQL [7]): LLM + chia nhỏ bài toán, chọn ví dụ few-shot, tự sửa lỗi. Hạn chế: dành cho bảng quan hệ; quan hệ nhiều bước phải JOIN, không có truy vấn đường đi.
- **KGQA – MetaQA** [5]: hỏi đáp 1–3 hop trên đồ thị tri thức phim. Hạn chế: câu hỏi sinh từ template, trả lời bằng mô hình suy luận chứ không sinh truy vấn nên khó giải thích, khó đổi domain.
- **Neo4j Text2Cypher 2024** [2][3]: 44.387 cặp (câu hỏi, schema, Cypher) gộp từ 16 nguồn; có mô hình Gemma-2-9B fine-tune [10]. Hạn chế: ít dữ liệu mạng xã hội, fine-tune cần GPU.
- **LangChain GraphCypherQAChain** [9]: đưa schema + câu hỏi cho LLM sinh Cypher rồi diễn giải kết quả. Hạn chế: zero-shot, không liên kết thực thể, không tự sửa khi truy vấn lỗi/rỗng.
- **LDBC SNB** [1]: benchmark chuẩn cho graph database, có generator và bộ truy vấn Cypher mẫu. Hạn chế: chỉ đo hiệu năng hệ quản trị, không có câu hỏi ngôn ngữ tự nhiên.

3. Data

- **LDBC SNB Interactive v1, SF0.1** [1] — nguồn: ldbcouncil.org/benchmarks/snb/datasets, định dạng CsvComposite + LongDateFormatter. Mạng xã hội tổng hợp mô phỏng người dùng, bài viết, bình luận, diễn đàn, tag, địa điểm, tổ chức; thời gian 01/2010–09/2012. Đã nạp vào Neo4j và đếm lại (khớp 100% số dòng CSV):

Thành phần	Số lượng	Thành phần	Số lượng
Tổng node	327.588	Tổng cạnh	1.477.965
Person	1.528	KNOWS	14.073
Post / Comment	135.701 / 151.043	LIKES	109.440
Forum	13.750	HAS_MEMBER	123.268
Tag / TagClass	16.080 / 71	HAS_TAG	290.118
Place / Organisation	1.460 / 7.955	Loại node / cạnh	8 / 15

- Mạng KNOWS: bậc trung bình 18,4, trung vị 9, lớn nhất 340; 171 người không có bạn. Ưu điểm: schema giàu, có truy vấn Cypher mẫu, dữ liệu tổng hợp nên LLM không biết trước đáp án. Rủi ro: không phải dữ liệu thật; trang tải không ghi rõ license dữ liệu (mã nguồn LDBC dùng Apache-2.0).

- **Bộ câu hỏi QA (tự xây dựng)**: 242 câu tiếng Anh thuộc 5 loại, sinh từ 25 template do nhóm tự viết (5 template/loại; không chép các truy vấn LDBC công khai); tham số lấy ngẫu nhiên từ đồ thị với seed cố định; đáp án đúng = kết quả chạy Cypher gold, không ghi tay. Đã chia dev 92 câu / test 150 câu (30 câu/loại), test đóng băng bằng SHA-256; kiểm tra chéo 50 câu (20% mỗi loại) đạt 50/50 câu khớp.
- **Guideline tạo Q/A** (eval/QA_GUIDELINE.md) để 6 người viết nhất quán và tránh đáp án sai: (i) quy ước ngữ nghĩa chung — "bạn" = KNOWS không xét chiều (dữ liệu lưu mỗi cặp bạn một cạnh một chiều, viết có chiều sẽ sót ~nửa số bạn), "bài viết" = Post, "bạn của bạn" không gồm bạn trực tiếp, năm theo UTC, đếm luôn DISTINCT; (ii) loại câu có đáp án rỗng/0, đồng hạng, thực thể trùng họ tên (166 trường hợp) hoặc mơ hồ; (iii) script tự kiểm tra cú pháp, trùng lặp, thời gian chạy; (iv) kiểm tra chéo: 20% câu mỗi loại do người khác viết Cypher độc lập, báo tỉ lệ đồng thuận, câu bất đồng được sửa hoặc loại, loại nào đồng thuận < 90% thì soát lại toàn bộ.
- **Neo4j Text2Cypher 2024** [3] (Apache-2.0): chỉ dùng tham khảo mẫu câu và ví dụ few-shot.

4. Evaluation

- **Thực tế:** người dùng không biết Cypher nhận được câu trả lời đúng trong vài giây; khi không chắc chắn (tên trùng, không tìm thấy) hệ thống nói rõ thay vì trả lời sai.
- **Thí nghiệm – metrics:** (1) Execution Accuracy (chính): kết quả truy vấn sinh ra khớp kết quả truy vấn gold (so theo tập giá trị, không phụ thuộc tên cột); (2) tỉ lệ truy vấn chạy được; (3) tỉ lệ kết quả rỗng; (4) độ trễ và số lời gọi LLM mỗi câu. Báo cáo theo loại câu hỏi và cỡ model.
- **Protocol:** chia theo template thành dev (92 câu, dùng chỉnh prompt và làm kho ví dụ few-shot) và test (150 câu); cố định ID model, temperature 0, ghi ngày chạy và lưu toàn bộ output, chạy 3 lần, báo trung bình ± độ lệch; mọi baseline dùng cùng tập test, cùng thông tin schema và cùng cách chấm; chấm thủ công 50 câu trả lời văn bản về độ trung thực.
- **Chống rò rỉ dữ liệu:** (1) template và thực thể (người, tag, forum) không trùng giữa dev và test; few-shot (C) chỉ lấy từ dev; (2) prompt, luật của B0 và mọi lựa chọn thiết kế chỉ chỉnh trên dev — test chỉ chạy một lần cuối cho mỗi cấu hình, khóa bằng mã băm SHA-256; (3) vòng tự sửa lỗi (D) chỉ nhận thông báo lỗi/kết quả rỗng, không bao giờ nhận đáp án gold; (4) rò rỉ từ dữ liệu huấn luyện của LLM: template tự viết thay vì truy vấn LDBC công khai, và giá trị đáp án là dữ liệu tổng hợp nên không thể có sẵn trên internet; không dùng câu test để fine-tune.

5. Baselines

- **B0 – Template/rule-based:** nhận diện ý định bằng từ khóa + điền tham số vào mẫu Cypher cho 5 loại câu hỏi.
- **B1 – LLM zero-shot:** gpt-oss-20b (openai/gpt-oss-20b, model production trên Groq) + schema tự trích từ Neo4j + câu hỏi → Cypher (khung đánh giá: eval/run_eval.py).
- **B2 – LangChain GraphCypherQAChain** [9] cấu hình mặc định, cùng LLM với B1.
- **B3 – LLM mạnh zero-shot** (mốc tham chiếu trên): gpt-oss-120b (openai/gpt-oss-120b) trên Groq; tùy chọn thêm Gemini hoặc model Text2Cypher fine-tune sẵn của Neo4j [10]. Cùng prompt, schema, tập test và cách chấm như B1; B1 và B3 cùng họ gpt-oss (20B và 120B) nên khác biệt chủ yếu do cỡ model. Mục đích: không kết luận chỉ dựa trên việc thắng một model yếu.

6. Proposed Method

- Pipeline 4 thành phần quanh cùng LLM của B1: **(A) schema chi tiết** (thuộc tính theo nhãn, chiều cạnh, giá trị mẫu); **(B) liên kết thực thể**: tìm tên trong câu hỏi bằng full-text index để chuẩn hóa ("United States"→United_States) và phát hiện trùng tên; **(C) few-shot động**: chọn ví dụ tương tự từ tập dev; **(D) tự sửa lỗi**: chạy thử, nếu lỗi cú pháp/kết quả rỗng thì gửi lỗi cho LLM sửa (tối đa 2 lần); cuối cùng LLM diễn giải kết quả thành câu trả lời.
- Vì sao nên hiệu quả (giả thuyết, sẽ kiểm chứng bằng phân tích lỗi của B1): phần lớn lỗi đến từ sai tên thuộc tính/giá trị và sai chiều cạnh hơn là từ suy luận; (A)(B) neo LLM vào dữ liệu thật, (D) sửa lỗi dựa trên phản hồi thực thi — hướng đã hiệu quả trong Text-to-SQL [6][7][8].

7. Expected Results

- **Kết quả kỳ vọng:** B1 > B0 ở multi-hop/đường đi; pipeline đề xuất > B1, B2 (mục tiêu ≥ 10 điểm % execution accuracy trên test); B3 > B1, và pipeline đề xuất trên model nhỏ thu hẹp đáng kể khoảng cách tới B3. Thí nghiệm cần: E1 so sánh B0–B3 với proposed; E2 ablation bỏ lần lượt A, B, C, D; E3 áp dụng pipeline lên model mạnh để đo lợi ích còn lại; E4 phân tích lỗi theo loại câu hỏi và theo model.
- **Backup plan:** nếu proposed không vượt baseline → báo cáo phân tích lỗi và dùng bộ định tuyến lai (rule cho câu đơn giản, LLM cho câu phức tạp); Groq đã gỡ Llama-3.1-8B/3.3-70B nên nhóm chuyển sang gpt-oss-20b/120b (đã thực hiện); nếu Groq tiếp tục gỡ model hoặc hạn mức không đủ → chạy cùng model mở (gpt-oss-20b) qua Ollama trên máy mạnh nhất nhóm hoặc nâng gói trả phí, output đã cache vẫn chấm lại được; nếu không đủ hạn mức cho mọi lần chạy → ablation (E2) chạy 1 lần thay vì 3; nếu thiếu thời gian → giảm bộ test còn 100 câu.

References

- [1] R. Angles et al., "The LDBC Social Network Benchmark," arXiv:2001.02299, 2020. [Online]. Available: https://arxiv.org/abs/2001.02299
- [2] M. G. Ozsoy, L. Messallem, J. Besga, and G. Minneci, "Text2Cypher: Bridging Natural Language and Graph Databases," in *Proc. Workshop on Generative AI and Knowledge Graphs (GenAIK)*, 2025. arXiv:2412.10064.
- [3] Neo4j, "neo4j/text2cypher-2024v1," Hugging Face Datasets, 2024. [Online]. Available: https://huggingface.co/datasets/neo4j/text2cypher-2024v1
- [4] T. Yu et al., "Spider: A Large-Scale Human-Labeled Dataset for Complex and Cross-Domain Semantic Parsing and Text-to-SQL Task," in *Proc. EMNLP*, Brussels, Belgium, 2018, pp. 3911–3921.
- [5] Y. Zhang, H. Dai, Z. Kozareva, A. J. Smola, and L. Song, "Variational Reasoning for Question Answering with Knowledge Graph," in *Proc. AAAI Conf. Artificial Intelligence*, 2018.
- [6] M. Pourreza and D. Rafiei, "DIN-SQL: Decomposed In-Context Learning of Text-to-SQL with Self-Correction," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- [7] D. Gao et al., "Text-to-SQL Empowered by Large Language Models: A Benchmark Evaluation," *Proc. VLDB Endowment*, vol. 17, no. 5, pp. 1132–1145, 2024.
- [8] X. Chen, M. Lin, N. Schärli, and D. Zhou, "Teaching Large Language Models to Self-Debug," in *Proc. Int. Conf. Learning Representations (ICLR)*, 2024.
- [9] LangChain, "langchain-neo4j: GraphCypherQAChain," GitHub repository. [Online]. Available: https://github.com/langchain-ai/langchain-neo4j (accessed Sep. 2026).
- [10] Neo4j, "text2cypher-gemma-2-9b-it-finetuned-2024v1," Hugging Face Models, 2024. [Online]. Available: https://huggingface.co/neo4j/text2cypher-gemma-2-9b-it-finetuned-2024v1

Appendix

1. Timeline

Thời gian 21/9/2026 – 27/12/2026 (14 tuần). Phân công dự kiến, điều chỉnh theo tiến độ thực tế; danh sách công việc chi tiết, người review, giờ ước tính và trạng thái theo dõi trong file Phan_cong_Nhom13_GraphQA.xlsx. Kiểm tra chéo câu hỏi theo vòng Bảo → Khôi → Ân → Bảo và Bằng ↔ Vũ. Ân và Bằng phụ trách các phần cốt lõi (liên kết thực thể, tự sửa lỗi, tích hợp pipeline, E1 và E2) và review chéo cho nhau.

Tuần	Thời gian	Công việc chi tiết	Phụ trách
1	21/9 – 27/9	Khảo sát đề tài, chọn dataset, cài Neo4j, nạp LDBC SF0.1, thống kê dữ liệu (đã xong)	Bảo
2	28/9 – 4/10	Viết proposal v1, related work, chuẩn bị review (Bảo); biên tập, rà soát proposal (Hương) (đã xong)	Bảo, Hương
3–4	5/10 – 18/10	Sửa proposal v2 (Bảo); dựng Neo4j server chung (Khôi); bộ câu hỏi QA theo guideline — template + Cypher gold: lookup (Bảo), aggregation (Bằng), multi-hop (Vũ), path (Ân), temporal (Khôi); diễn đạt câu hỏi tự nhiên, phổ biến guideline, tổng hợp kiểm tra chéo (Hương); script sinh câu, chia dev/test (Bảo) (bộ câu hỏi và proposal v2 đã xong)	Cả nhóm
5	19/10 – 25/10	Backend Groq + pipeline đánh giá + chạy B1, B3 trên test (Bằng, đã xong 21/10); B0 rule-based và B2 GraphCypherQAChain (Vũ); kiểm thử bộ chấm điểm (Ân); cập nhật proposal v3 (Bằng, đã xong 21/10)	Bằng, Vũ, Ân
6–8	26/10 – 15/11	Pipeline đề xuất — phần lõi: (B) liên kết thực thể (Ân), (D) tự sửa lỗi + sinh câu trả lời và tích hợp A–D (Bằng); phần phụ: (A) schema chi tiết (Khôi), (C) few-shot động (Vũ); viết mục Related work/Data và tiêu chí chấm tay (Hương)	Ân, Bằng (chính); Khôi, Vũ, Hương
9–10	16/11 – 29/11	E1 so sánh chính + B3 (Bằng); E2 ablation (Ân); E3 (Vũ); script chạy theo lô (Bảo); mỗi thí nghiệm 3 lần; chấm tay 50 câu trả lời, bảng và biểu đồ kết quả (Hương)	Bằng, Ân (chính); Vũ, Bảo, Hương
11	30/11 – 6/12	Giao diện Streamlit (Khôi); E4 phân tích lỗi: phân tích nguyên nhân kỹ thuật (Ân), gán nhãn lỗi (Hương)	Ân, Khôi, Hương
12	7/12 – 13/12	Dự phòng: chạy lại thí nghiệm, sửa lỗi, demo nội bộ (Bảo điều phối)	Cả nhóm
13–14	14/12 – 27/12	Báo cáo và slide (Hương chủ trì biên tập, mỗi người viết phần mình, Bảo viết Method/Experiments); dọn mã nguồn, README tái lập (Vũ); demo và video demo (Khôi)	Cả nhóm

2. Additional content (if any)

- **Cập nhật phiên bản 3 (21/10/2026):** các thay đổi so với bản 2.
- **Model:** Groq đã gỡ Llama-3.1-8B và Llama-3.3-70B (16/08/2026). Nhóm dùng gpt-oss-20b cho B1, B2 và hệ thống đề xuất (model yếu), gpt-oss-120b cho B3 và E3 (model mạnh), cùng trên Groq.
- **Số liệu thật:** bộ câu hỏi 242 câu (dev 92 / test 150), kiểm tra chéo 50/50 câu khớp; hạn mức Groq đo thực tế khoảng 200K token/ngày mỗi model.
- **Đánh giá:** khung eval/run_eval.py chạy truy vấn ở chế độ chỉ đọc, timeout 30 s, gán 7 nhãn; kiểm chứng bằng oracle (trả về đúng Cypher gold) đạt 100% trên dev và test.
- **Kết quả giữa kỳ:** trên 150 câu test, B1 (gpt-oss-20b) đạt EX 48,7% (1 lượt), B3 (gpt-oss-120b) đạt 78,9 ± 1,7% (3 lượt). Bản thử proposed v0 (A + D) trên 70/92 câu dev đạt 98,6% so với 61,4% của B1 trên cùng các câu; đây là kết quả sơ bộ vì dev cũng là nơi chỉnh prompt. Chi tiết trong results/midterm/RESULTS.md.

3. Experimental plan (proposal version 3)

1. Dataset:

- Đồ thị: LDBC SNB Interactive v1, SF0.1 (CsvComposite + LongDateFormatter), nạp vào Neo4j 5 Community. Số liệu đếm trực tiếp trong Neo4j (Place = City + Country + Continent; Organisation = University + Company; Message = Post + Comment):

Loại node	Số lượng	Kiểu quan hệ	Số lượng
Post	135.701	IS_LOCATED_IN	296.227
Comment	151.043	HAS_TAG	290.118
Forum	13.750	HAS_CREATOR	286.744
Tag	16.080	REPLY_OF	151.043
TagClass	71	CONTAINER_OF	135.701
Person	1.528	HAS_MEMBER	123.268
City	1.343	LIKES	109.440
Country	111	HAS_INTEREST	35.475
Continent	6	HAS_TYPE	16.080
University	6.380	KNOWS	14.073
Company	1.575	HAS_MODERATOR	13.750
		WORK_AT	3.313
		IS_PART_OF	1.454
		STUDY_AT	1.209
		IS_SUBCLASS_OF	70
Tổng node	**327.588**	**Tổng cạnh**	**1.477.965**

- Bộ câu hỏi QA – thống kê dev/test (số thực, chia ngày 19/10/2026; 8 câu dev trùng thực thể với test đã bị bỏ). Không có tập train vì đồ án không huấn luyện/fine-tune model; dev dùng chỉnh prompt và làm kho ví dụ few-shot, test chỉ dùng cho đánh giá cuối:

Loại câu hỏi	Template (dev / test)	Câu hỏi dev	Câu hỏi test
lookup	2 / 3	17	30
aggregation	2 / 3	20	30
multi_hop	2 / 3	20	30
path	2 / 3	16	30
temporal	2 / 3	19	30
Tổng	**10 / 15**	**92**	**150**

- Data pipeline: (1) CSV LDBC → scripts/load_ldbc.py (tạo constraint/index, đổi epoch-ms sang datetime UTC, gán nhãn phụ City/Country/Continent, University/Company) → Neo4j → scripts/stats.py đối chiếu số lượng với CSV (khớp 100%). (2) Template + Cypher có tham số → script sinh câu (seed cố định) → lọc tự động (đáp án rỗng/0, đồng hạng, trùng họ tên, chạy > 10 s) → kiểm tra chéo 20% (50 câu, 50/50 khớp) → chia dev/test theo template và thực thể → đóng băng test.json bằng mã băm SHA-256 (chi tiết: eval/QA_GUIDELINE.md).

2. Evaluation Protocol:

- Pipeline đánh giá: câu hỏi → hệ thống (baseline/proposed) → Cypher → chạy trên Neo4j ở chế độ chỉ đọc (timeout 30 s) → so tập kết quả với kết quả của Cypher gold (bỏ cột đếm phụ, chuẩn hóa chữ hoa/thường và số thực) → gán nhãn correct / wrong_result / empty_result / execution_error / timeout / no_cypher / llm_error (khung: eval/run_eval.py; kiểm chứng bằng oracle trả về đúng Cypher gold: 100% trên dev và test). Lưu toàn bộ prompt, output, thời gian và số lời gọi LLM (JSON) để chấm lại mà không cần gọi lại API.
- Dữ liệu đánh giá: tập test (150 câu) cho kết quả chính; dev chỉ dùng khi phát triển.
- Metrics: Execution Accuracy = số câu correct / tổng số câu (chính); Valid rate = tỉ lệ Cypher chạy không lỗi; Empty rate; độ trễ trung bình và số lời gọi LLM mỗi câu; độ trung thực câu trả lời văn bản (chấm tay 50 câu). Báo theo loại câu hỏi, trung bình ± độ lệch chuẩn qua 3 lần chạy.

3. Baseline:

- B0 – Rule-based: so khớp từ khóa/regex → chọn một trong ~10 mẫu Cypher → điền tên thực thể; luật chỉ viết dựa trên tập dev.
- B1 – gpt-oss-20b zero-shot (Groq): chỉ dẫn + schema tự trích + câu hỏi; temperature 0.
- B2 – GraphCypherQAChain (langchain-neo4j) cấu hình mặc định, cùng model với B1.
- B3 – Model mạnh zero-shot: gpt-oss-120b (Groq), cùng prompt với B1.

4. Proposed Method:

- Cùng model với B1, bốn thành phần chạy tuần tự: (A) schema chi tiết — thuộc tính theo từng nhãn, chiều cạnh, giá trị mẫu và quy ước (KNOWS không xét chiều, Person→City→Country); (B) liên kết thực thể — trích cụm tên trong câu hỏi, tra full-text index trên tên Person/Place/Tag/Organisation/Forum, thay bằng giá trị thật trong DB, nếu một tên khớp nhiều người thì yêu cầu làm rõ; (C) few-shot động — chọn k = 3 ví dụ dev gần nhất với câu hỏi theo độ tương đồng văn bản; (D) tự sửa lỗi — nếu Cypher lỗi cú pháp hoặc trả về rỗng thì gửi thông báo lỗi cho LLM sửa, tối đa 2 lần,

không bao giờ dùng đáp án gold. Bước cuối: LLM diễn giải kết quả truy vấn thành câu trả lời.

5. Ablation:

- Ablation 1 – bỏ (A): dùng schema tự trích như B1.
- Ablation 2 – bỏ (B): không liên kết thực thể.
- Ablation 3 – bỏ (C): không ví dụ few-shot.
- Ablation 4 – bỏ (D): không tự sửa lỗi.
- So EX và phân bố lỗi theo loại câu hỏi với bản đầy đủ để xác định thành phần đóng góp nhiều nhất (RQ2).

6. Experiment specifications:

- Experiment 1 (E1 – so sánh chính, RQ1): B0, B1, B2, B3, Proposed trên tập test; 3 lần chạy; đủ các metrics; báo theo loại câu hỏi.
- Experiment 2 (E2 – ablation, RQ2): Proposed đầy đủ và Ablation 1–4 trên tập test, cùng gpt-oss-20b; 3 lần chạy.
- Experiment 3 (E3 – model mạnh, RQ3): áp dụng pipeline đề xuất lên gpt-oss-120b; so với B3 (120B zero-shot) và Proposed (20B).
- Experiment 4 (E4 – phân tích lỗi): phân loại thủ công các câu sai của B1, Proposed và B3 theo nhóm: sai nhãn/thuộc tính, sai giá trị thực thể, sai chiều cạnh, sai logic tổng hợp/đếm, sai điều kiện thời gian, lỗi cú pháp.
- Ước tính số lời gọi LLM: E1 ≈ 4 cấu hình dùng LLM × 150 câu × 3 lần ≈ 1.800; E2 ≈ 4 × 150 × 3 ≈ 1.800; E3 ≈ 450; cộng lời gọi tự sửa lỗi, sinh câu trả lời và B2 (×1,5–2) → khoảng 6.000–8.000 lời gọi, phần lớn trên gpt-oss-20b. Với hạn mức đo thực tế (khoảng 200K token/ngày mỗi model, mỗi lời gọi khoảng 1.000–1.300 token), riêng gpt-oss-20b cần khoảng 4 tuần hạn mức nếu chỉ dùng gói miễn phí → chạy mỗi thí nghiệm ngay khi thành phần sẵn sàng, rải đều nhiều tuần, hoặc nâng gói trả phí.